

PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO
TÓPICOS ESPECIAIS EM FUNDAMENTOS DE COMPUTAÇÃO – MATEMÁTICA E ESTATÍSTICA PARA CIÊNCIA DE DADOS
Prof. Dr. Rommel Melgaço Barbosa

Seminários

Decomposição de Matrizes


Hudson Romualdo

Fábio Pereira

André Riccioppo

Gabriel Almeida

Abril/2024



UFG
UNIVERSIDADE
FEDERAL DE GOIÁS



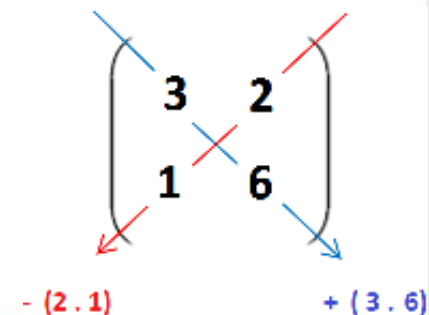
Características numéricas de Matrizes

Hudson de Paula Romualdo



Determinantes

- Os determinantes são conceitos importantes na álgebra linear.
- Um determinante é um objeto matemático na análise e solução de sistemas de equações lineares.
- Os determinantes são definidos apenas para matrizes quadradas $A \in \mathbb{R}^{n \times n}$, ou seja, matrizes com o mesmo número de linhas e colunas.



The diagram shows a 2x2 matrix with elements 3, 2, 1, and 6. A blue arrow points from 3 down to 6, and a red arrow points from 2 down to 1. Below the matrix, the signs for the cofactors are indicated: a red minus sign for the first column and a blue plus sign for the second column.

$$\begin{pmatrix} 3 & 2 \\ 1 & 6 \end{pmatrix}$$

- (2 . 1) + (3 . 6)



- O determinante de uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ é uma função que mapeia \mathbf{A} em um número real.

$$\det(\mathbf{A}) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix}$$

- Em uma expressão, a determinante de uma matriz \mathbf{A} pode ser representado por $\det(\mathbf{A})$ ou por $|\mathbf{A}|$.



Aplicação: Testando a invertibilidade da Matriz

- Verificar a invertibilidade de uma matriz é crucial pois ela determina a existência de soluções para sistemas de equações, entre outros usos.
- Se A é uma matriz 1×1 , ou seja, é um número escalar, temos:
 - $A = a \Rightarrow A^{-1} = \frac{1}{a}$. Então $a \frac{1}{a} = 1$ se mantém, se e somente se $a \neq 0$.
- Para matrizes 2×2 sabemos que $AA^{-1} = I$. Então, inverso de A é:

$$A^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}$$



- Portanto, A é inversível se e somente se:

$$a_{11}a_{22} - a_{12}a_{21} \neq 0$$

- O resultado dessa expressão é o determinante de uma matriz $A \in \mathbb{R}^{2 \times 2}$:

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}$$


- Só é possível inverter qualquer matriz $A \in \mathbb{R}^{n \times n}$ se e somente se $\det(A) \neq 0$.



Regra de Sarrus: determinante de matrizes de ordem 3

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{21}a_{32}a_{13} + a_{31}a_{12}a_{23} \\ - a_{31}a_{22}a_{13} - a_{11}a_{32}a_{23} - a_{21}a_{12}a_{33} .$$

- Exemplo:



Determinante de matrizes Triangulares


- Chamamos uma matriz quadrada T de uma matriz triangular superior se $T_{ij} = 0$ para todo $i > j$, ou seja, os valores da matriz são zero abaixo da sua diagonal principal. Analogamente, definimos uma matriz triangular inferior como uma matriz com zeros acima da sua diagonal principal.
- Para uma matriz triangular $T \in \mathbb{R}^{n \times n}$, o determinante é o produto dos elementos da diagonal principal, ou seja:

$$\det(T) = \prod_{i=1}^n T_{ii}$$




Aplicação: Determinantes como Medida de Área e Volume

- A noção de determinante é natural quando a consideramos como uma função de um conjunto de n vetores que abrangem um objeto em \mathbb{R}^n .
- Para $n = 2$, as colunas da matriz formam um paralelogramo.




- Considere dois vetores b , g que formam as colunas de uma matriz $A = [b, g]$. Então, o valor absoluto do determinante de A é a área do paralelogramo com vértices $0, b, g, b + g$.




- Em particular, se b , g são linearmente dependentes de forma que $b = \lambda g$ para algum $\lambda \in \mathbb{R}$, eles não formam mais um paralelogramo bidimensional. Portanto, a área correspondente é 0.



- Se b, g são linearmente independentes e são múltiplos dos vetores da base canônica e_1, e_2 , então eles podem ser escritos como $b \begin{bmatrix} b \\ 0 \end{bmatrix}$ e $g \begin{bmatrix} 0 \\ g \end{bmatrix}$, e o determinante é $\begin{vmatrix} b & 0 \\ 0 & b \end{vmatrix} = bg - 0 = bg$.
- A fórmula parece familiar: *área = altura \times comprimento*.
- No paralelogramo formado por b, g , a base do paralelogramo tem um comprimento $\|g\|$ e a altura tem um comprimento $\|b\| \sin \theta$. Isso significa que a área (parte sombreada) do paralelogramo no total é exatamente a magnitude do produto vetorial.




- Essa intuição se estende a dimensões superiores.
- Em \mathbb{R}^3 , consideramos três vetores $r, b, g \in \mathbb{R}^3$ que abrangem as arestas de um paralelepípedo, ou seja, um sólido com faces que são paralelogramos.
- O valor absoluto do determinante da matriz $3 \times 3 [r, b, g]$ é o volume do sólido. Assim, o determinante age como uma função que mede o volume assinado formado por vetores coluna compostos em uma matriz.



$$\mathbf{r} = \begin{bmatrix} 2 \\ 0 \\ -8 \end{bmatrix}, \quad \mathbf{g} = \begin{bmatrix} 6 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 4 \\ -1 \end{bmatrix}$$

$$\mathbf{A} = [\mathbf{r}, \mathbf{g}, \mathbf{b}] = \begin{bmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ -8 & 0 & -1 \end{bmatrix}$$



Regra de Sarrus:

$$\begin{array}{ccc|ccc} 2 & 6 & 1 & 2 & 6 & 1 \\ 0 & 1 & 4 & 0 & 1 & 4 \\ -8 & 0 & -1 & -8 & 0 & -1 \end{array}$$

Blue arrows indicate the downward diagonal products (2*1*(-8), 6*4*(-8), 1*0*0). Yellow arrows indicate the upward diagonal products (2*4*0, 6*0*(-8), 1*(-8)*0).

$$V = |\det(\mathbf{A})| = |8 - 2 - 192| = 186$$



Expansão de Laplace

- Calcular o determinante de uma matriz $n \times n$ requer um algoritmo geral para resolver os casos para $n > 3$, a expansão de Laplace.
- O uso do teorema reduz o problema de calcular o determinante de uma matriz de ordem superior a 3 aplicando a expansão recursivamente até o calculo de determinantes de matrizes 2×2 no final.



- Considere uma matriz $A \in \mathbb{R}^{n \times n}$. Então, para todo $j = 1, \dots, n$:
 - Expansão ao longo da coluna j

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{kj} \det(A_{k,j})$$

- Expansão ao longo da linha j

$$\det(A) = \sum_{k=1}^n (-1)^{k+j} a_{jk} \det(A_{j,k})$$

- Aqui $A_{k,j} \in \mathbb{R}^{(n-1) \times (n-1)}$ é a submatriz de A que obtemos ao excluir a linha k e a coluna j .

$$|A_{3 \times 3}| = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix}$$



$$\mathbf{A} = [\mathbf{r}, \mathbf{g}, \mathbf{b}] = \begin{bmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ -8 & 0 & -1 \end{bmatrix}$$

$$(-1)^{1+1} \cdot 2 \cdot \det \begin{pmatrix} 1 & 4 \\ 0 & -1 \end{pmatrix} = 1 \cdot 2 \cdot -1 = -2$$

$$(-1)^{1+2} \cdot 6 \cdot \det \begin{pmatrix} 0 & 4 \\ -8 & -1 \end{pmatrix} = -1 \cdot 6 \cdot 32 = -192$$

$$(-1)^{1+3} \cdot 1 \cdot \det \begin{pmatrix} 0 & 1 \\ -8 & 0 \end{pmatrix} = 1 \cdot 1 \cdot 8 = 8$$

$$|-2 - 192 + 8| = 186$$

$$\begin{array}{ccc|ccc} 2 & 6 & 1 & 2 & 6 & \\ 0 & 1 & 4 & 0 & 1 & \\ -8 & 0 & -1 & -8 & 0 & \end{array}$$

$$V = |\det(\mathbf{A})| = |8 - 2 - 192| = 186$$



Propriedades

Para $A \in \mathbb{R}^{n \times n}$, o determinante exhibe as seguintes propriedades:

- O determinante de um produto de matrizes é o produto dos determinantes correspondentes, $\det(\mathbf{AB}) = \det(\mathbf{A}) \cdot \det(\mathbf{B})$
- Os determinantes são invariantes à transposição, ou seja, $\det(\mathbf{A}) = \det(\mathbf{A}^T)$.
- Se A é regular (invertível), então $\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}$
- Matrizes semelhantes possuem o mesmo determinante. Portanto, para um mapeamento linear $\Phi : V \rightarrow V$ todas as matrizes de transformação A_Φ de Φ têm o mesmo determinante. Assim, o determinante é invariante à escolha da base de um mapeamento linear.



- Adicionar um múltiplo de uma coluna/linha a uma outra não altera $\det(\mathbf{A})$.
- A multiplicação de uma coluna/linha com $\lambda \in \mathbb{R}$ dimensiona $\det(\mathbf{A})$ por λ . Em particular, $\det(\lambda \mathbf{A}) = \lambda^n \det(\mathbf{A})$.
- Trocar duas linhas/colunas altera o sinal de $\det(\mathbf{A})$.

Devido às últimas três propriedades, podemos usar a Eliminação de Gauss para calcular $\det(\mathbf{A})$ trazendo \mathbf{A} para a forma escalonada por linhas. Podemos parar a eliminação quando tivermos \mathbf{A} na forma de uma matriz triangular superior uma vez que o determinante de uma matriz triangular é o produto dos elementos diagonais.



- Uma matriz quadrada $A \in \mathbb{R}^{n \times n}$ tem $\det(A) \neq 0$ se e somente se $rk(A) = n$.
- Em outras palavras, A é invertível se e somente se tiver posto completo.
- O posto é o número máximo de colunas/linhas linearmente independentes de uma Matriz. Se a matriz for quadrada, e o posto for igual ao número de linhas, então a matriz tem posto completo.



Traço

O traço de uma matriz quadrada $A \in \mathbb{R}^{n \times n}$ é definido como:

$$\text{tr}(A) := \sum_{i=1}^n a_{ii} ,$$

, isto é, o traço é a soma dos elementos da diagonal principal de A .

$$A = \begin{pmatrix} \mathbf{a_{11}} & a_{12} & a_{13} & a_{14} \\ a_{21} & \mathbf{a_{22}} & a_{23} & a_{24} \\ a_{31} & a_{32} & \mathbf{a_{33}} & a_{34} \\ a_{41} & a_{42} & a_{43} & \mathbf{a_{44}} \end{pmatrix}$$

$$\text{tr } A = a_{11} + a_{22} + a_{33} + a_{44}$$



O Traço satisfaz as seguintes propriedades:

- $tr(\mathbf{A} + \mathbf{B}) = tr(\mathbf{A}) + tr(\mathbf{B})$ para $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$
- $tr(\alpha \mathbf{A}) = \alpha \cdot tr(\mathbf{A})$, para $\alpha \in \mathbb{R}$ e $\mathbf{A} \in \mathbb{R}^{n \times n}$
- $tr(\mathbf{I}_n) = n$
- $tr(\mathbf{AB}) = tr(\mathbf{BA})$ para $\mathbf{A} \in \mathbb{R}^{n \times k}, \mathbf{B} \in \mathbb{R}^{k \times n}$

$$\mathbf{A} = \begin{bmatrix} 1 & 3 & 5 \\ 7 & 9 & 2 \\ 4 & 6 & 8 \end{bmatrix}$$

$$tr(\mathbf{A}) = 18$$

$$tr(\mathbf{AB}) = tr(\mathbf{BA})$$

$$tr(k\mathbf{A}) = k \cdot tr(\mathbf{A})$$

$$tr(\mathbf{A}) = tr(\mathbf{A}^T)$$



As propriedades do traço dos produtos de matrizes são mais gerais. Especificamente, o traço é invariante sob permutações cíclicas, ou seja,

$$\text{tr}(\mathbf{AKL}) = \text{tr}(\mathbf{KLA})$$

para matrizes $\mathbf{A} \in \mathbb{R}^{a \times n}$, $\mathbf{K} \in \mathbb{R}^{k \times l}$, $\mathbf{L} \in \mathbb{R}^{l \times a}$.

Esta propriedade generaliza para produtos de um número arbitrário de matrizes.



Dado um mapeamento linear $\Phi : V \rightarrow V$, onde V é um espaço vetorial, definimos o traço desse mapa usando o traço da representação matricial de Φ . Para uma base dada de V , podemos descrever Φ por meio da matriz de transformação A . Então, o traço de Φ é o traço de A .

Para uma base diferente de V , vale a pena mencionar que a matriz de transformação correspondente B de Φ pode ser obtida por uma mudança de base da forma $S^{-1}AS$ para um S adequado.

Para o traço correspondente de Φ , isso significa que: $tr(B) = tr(S^{-1}AS) = tr(ASS^{-1}) = tr(A)$.

Portanto, embora as representações matriciais de mapeamentos lineares sejam dependentes da base, o traço de um mapeamento linear Φ é independente da base.



Polinômio Característico

Para $\lambda \in \mathbb{R}$ e uma matriz quadrada $A \in \mathbb{R}^{n \times n}$

$$p_A(\lambda) := \det(A - \lambda I)$$

$$= c_0 + c_1\lambda + c_2\lambda^2 + \cdots + c_{n-1}\lambda^{n-1} + (-1)^n\lambda^n,$$

$$c_0, \dots, c_{n-1} \in \mathbb{R}.$$

Adicionalmente:

$$c_0 = \det(A)$$

$$c_{n-1} = (-1)^{n-1} \text{tr}(A)$$


Este polinômio característico nos permitirá calcular autovalores e autovetores.



Autovalores e Autovetores

Assim como o Determinante e o Traço, Autovalores e Autovetores são características de Matrizes Quadradas.

- Autovalores são valores numéricos que descrevem a **magnitude** da transformação efetuada por uma matriz em uma determinada direção.
- Autovetores são vetores que fornecem a **direção** da transformação na qual a matriz age apenas esticando ou comprimindo o vetor, sem alterar sua orientação.



Motivação: Autovalores e Autovetores em PCA

Análise de Componentes Principais (PCA): é uma técnica que transforma dados de dimensões altas em dimensões inferiores, mantendo o máximo de informações possível.

cod_ibge	distritos	renda	quota	escolaridade	idade	mortalidade	txcresc	causasext	favel	denspop
1	Água Rasa	1961	3.461.999.893	7.599.999.905	32	1.385.999.966	-1.840.000.033	5.297.999.954	0.0	1.256.100.006
12	Alto de Pinheiros	4180	7.595.999.908	8.399.999.619	33	8.680.000.305	-2.519.999.981	3.856.999.969	0.689999998	5.756.000.137
23	Anhanguera	1093	4.5	5.800.000.191	23	1.535.999.966	1.812.000.084	2.268.000.031	0.0	8.569.999.695
34	Aricanduva	1311	2.102.000.046	6.800.000.191	27	1.843.000.031	-1.070.000.052	7.622.000.122	5.380.000.114	1.385.399.933
45	Artur Alvim	1248	1.590.999.985	7.0	27	1.972.999.954	-1.399.999.976	67.25	4.110.000.134	1.673.999.939
56	Barra Funda	2359	3.431.000.137	8.0	31	8.619.999.886	-2.140.000.105	3.790.000.153	4.849.999.905	2.560.000.038
67	Bela Vista	2400	5.365.000.153	8.399.999.619	32	1.240.999.985	-200.999.999	5.986.000.061	0.0	2.496.000.061
78	Belém	1813	3.198.999.977	7.699.999.809	32	1.127.000.046	-3.039.999.962	7.894.000.244	2.680.000.067	7.097.000.122
...										
90	Vila Mariana	3312	6.354.000.092	8.600.000.381	34	943.999.958	-1.330.000.043	3.318.000.031	0.870000005	1.444.100.037
91	Vila Matilde	1530	26.0	7.400.000.095	29	1.912.999.916	-1.830.000.043	5.872.999.954	0.0	1.116.999.969
92	Vila Medeiros	1405	1.976.000.023	6.800.000.191	27	1.543.000.031	-1.409.999.967	7.798.000.336	249.000.001	1.889.299.927
93	Vila Prudente	1755	3.208.000.183	7.199.999.809	30	1.435.999.966	-2.549.999.952	6.651.000.214	7.429.999.828	1.014.400.024
94	Vila Sônia	2970	4.140.999.985	7.400.000.095	27	1.676.000.023	-0.899999976	7.468.000.031	1.493.000.031	8.012.000.275



1. Padronização dos Dados: Se necessário, padronize os dados para que todas as variáveis tenham média zero e desvio padrão unitário.
2. Cálculo da Matriz de Covariância: Calcule a matriz de covariância dos dados padronizados para capturar as relações entre as variáveis.
3. Cálculo dos Autovalores e Autovetores: Calcule os autovalores e autovetores da matriz de covariância.
4. Ordenação dos Autovalores: Ordene os autovalores em ordem decrescente para identificar as componentes principais mais importantes.
5. Seleção das Componentes Principais: Selecione as primeiras k colunas dos autovetores correspondentes aos k maiores autovalores para obter as k componentes principais.
6. Projeção dos Dados: Projete os dados originais sobre as k componentes principais selecionadas para obter uma representação de menor dimensionalidade.



Seja $A \in \mathbb{R}^{n \times n}$ uma matriz quadrada. Então $\lambda \in \mathbb{R}$ é um autovalor de A e $x \in \mathbb{R}^n \setminus \{0\}$ é o autovetor correspondente de A se:

$$Ax = \lambda x$$

As seguintes afirmações são equivalentes:

- Se λ é um autovalor de $A \in \mathbb{R}^{n \times n}$.
- Existe um $x \in \mathbb{R}^n \setminus \{0\}$ tal que $Ax = \lambda x$, ou de forma equivalente, $(A - \lambda I_n)x = 0$ pode ser resolvido de forma não trivial, ou seja, $x \neq 0$.
- $rk(A - \lambda I_n) < n$.
- $\det(A - \lambda I_n) = 0$.



Colinearidade e Coodireção

Dois vetores que apontam na mesma direção são chamados de co-direcionados.

Dois vetores que apontam na mesma direção ou em direções opostas são chamados colineares.

Se \mathbf{x} é um autovetor de A associado ao autovalor λ , então para qualquer $c \in \mathbb{R} \setminus \{0\}$ temos que $c\mathbf{x}$ é um autovetor de A com o mesmo autovalor, pois:

$$A(c\mathbf{x}) = cA\mathbf{x} = c\lambda\mathbf{x} = \lambda(c\mathbf{x})$$

Assim, todos os vetores que são colineares a \mathbf{x} também são autovetores de A .



$\lambda \in \mathbb{R}$ é um autovalor de $A \in \mathbb{R}^{n \times n}$ se e somente se λ é uma raiz do polinômio característico $p_A(\lambda)$ de A .

Considerando que uma matriz quadrada A tenha um autovalor λ_i . A *multiplicidade algébrica* de λ_i é o número de vezes que a raiz aparece no polinômio característico.

O conjunto de todos os autovetores de A associados a um autovalor λ abrange um subespaço de \mathbb{R}^n , que é chamado de autoespaço de A com relação λ e é representado por E_λ .

O conjunto de todos os autovalores de A é chamado de autoespectro, ou apenas espectro, de A .



Se λ é um autovalor de $A \in \mathbb{R}^{n \times n}$ então o autoespaço correspondente E_λ é o espaço de soluções do sistema homogêneo de equações lineares $(A - \lambda I)x = 0$.

Geometricamente, o autovetor correspondente a um autovalor não nulo aponta em uma direção que é esticada pela transformação linear. O autovalor é o fator pelo qual ela é esticada. Se o autovalor for negativo, a direção é invertida.



O Caso da Matriz de Identidade

A matriz identidade $I \in \mathbb{R}^{n \times n}$ possui polinômio característico $p_I(\lambda) = \det(I - \lambda I) = (1 - \lambda)^n = 0$, o qual possui apenas um autovalor $\lambda = 1$ que ocorre n vezes. Além disso, $I\mathbf{x} = \lambda\mathbf{x} = 1\mathbf{x}$ é válido para todos os vetores $\mathbf{x} \in \mathbb{R}^n \setminus \{0\}$. Devido a isso, o único autoespaço E_1 da matriz identidade abrange n dimensões, e todos os n vetores da base padrão de \mathbb{R}^n são autovetores de I .

Os autovalores de uma **matriz triangular** são os elementos da **diagonal**

$$A = \begin{bmatrix} \frac{1}{2} & 0 & 0 \\ -1 & \frac{2}{3} & 0 \\ 5 & -8 & -\frac{1}{4} \end{bmatrix}$$



Propriedades úteis

- Uma matriz A e sua transposta A^T possuem os mesmos autovalores, mas não necessariamente os mesmos autovetores.
- O autoespaço E_λ é o espaço nulo de $A - \lambda I$, uma vez que:

$$Ax = \lambda x \iff Ax - \lambda x = 0$$

$$\iff (A - \lambda I)x = 0 \iff x \in \ker(A - \lambda I).$$



- Matrizes semelhantes possuem os mesmos autovalores. Portanto, um mapeamento linear Φ possui autovalores independentes da escolha da base de sua matriz de transformação. Isso torna os autovalores, juntamente com o determinante e o traço, parâmetros característicos principais de uma aplicação linear, pois são todos invariantes em relação à mudança de base.
- Matrizes simétricas e definidas positivas sempre têm autovalores reais e positivos.



Computando autovalores, autovetores e autoespaços

Vamos encontrar os autovalores e autovetores da matriz 2×2 :

$$A = \begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix}$$

Passo 1: Polinômio característico. A partir de nossa definição do autovetor $x \neq 0$ e autovalor λ de A , haverá um vetor tal que

$Ax = \lambda x$, ou seja, $(A - \lambda I)x = 0$. Desde que $x \neq 0$, isso requer que o núcleo (espaço nulo) de $A - \lambda I$ contenha mais elementos do que apenas 0. Isso significa que $A - \lambda I$ não é invertível e, portanto, $\det(A - \lambda I) = 0$.

Portanto, precisamos calcular as raízes do polinômio característico para encontrar os autovalores.



Passo 2: Autovalores. O polinômio característico é

$$\begin{aligned} p_{\mathbf{A}}(\lambda) &= \det(\mathbf{A} - \lambda \mathbf{I}) \\ &= \det \left(\begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right) = \begin{vmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{vmatrix} \\ &= (4 - \lambda)(3 - \lambda) - 2 \cdot 1. \end{aligned}$$

Fatorando o polinômio característico e obtemos:

$$p(\lambda) = (4 - \lambda)(3 - \lambda) - 2 \cdot 1 = 10 - 7\lambda + \lambda^2 = (2 - \lambda)(5 - \lambda)$$

obtendo as raízes $\lambda_1 = 2$ e $\lambda_2 = 5$.



Passo 3: Autovetores e autoespaços. Encontramos os autovetores que correspondem a esses autovalores examinando os vetores x tais que

$$\begin{bmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{bmatrix} x = 0.$$

Para $\lambda = 5$, obtemos

$$\begin{bmatrix} 4 - 5 & 2 \\ 1 & 3 - 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0.$$

Resolvemos este sistema homogêneo e obtemos um espaço de soluções.

$$E_5 = \text{span}\left[\begin{bmatrix} 2 \\ 1 \end{bmatrix}\right].$$

Este autoespaço é unidimensional, pois possui um único vetor de base.



Analogamente, encontramos o autovetor para $\lambda = 2$ resolvendo o sistema homogêneo de equações.

$$\begin{bmatrix} 4-2 & 2 \\ 1 & 3-2 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix} \mathbf{x} = \mathbf{0}.$$

Isso significa que qualquer vetor $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$, onde $x_2 = -x_1$, como $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$, é um autovetor com autovalor 2. O autoespaço correspondente é dado por

$$E_2 = \text{span}\left[\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right].$$



Os dois autoespaços E_5 e E_2 apresentados são unidimensionais, pois cada um é gerado por um único vetor.

$$E_5 = \text{span}\left[\begin{bmatrix} 2 \\ 1 \end{bmatrix}\right] \quad E_2 = \text{span}\left[\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right]$$

No entanto, em outros casos, podemos ter múltiplos autovalores idênticos e o autoespaço pode ter mais de uma dimensão.



Sendo λ_i um autovalor de uma matriz quadrada A . Então, a multiplicidade geométrica de λ_i é o número de autovetores linearmente independentes associados a λ_i . Em outras palavras, é a dimensionalidade do autoespaço gerado pelos autovetores associados a λ_i .

A multiplicidade geométrica de um autovalor específico deve ser pelo menos um, pois cada autovalor tem pelo menos um autovetor associado e não pode exceder sua multiplicidade algébrica, mas pode ser menor.

Exemplo:

A matriz $A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$ tem dois autovalores repetidos $\lambda_1 = \lambda_2 = 2$ e uma multiplicidade algébrica de 2. O autovalor tem, no entanto, apenas um autovetor $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ e, assim, multiplicidade geométrica 1.



Intuição Gráfica em Duas Dimensões


$$\mathbf{A}_1 = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{bmatrix} \quad \det(\mathbf{A}_1) = 1 = 2 \cdot \frac{1}{2}$$

$$\mathbf{A}_2 = \begin{bmatrix} 1 & \frac{1}{2} \\ 0 & 1 \end{bmatrix} \quad \det(\mathbf{A}_2) = 1$$

$$\mathbf{A}_3 = \begin{bmatrix} \cos(\frac{\pi}{6}) & -\sin(\frac{\pi}{6}) \\ \sin(\frac{\pi}{6}) & \cos(\frac{\pi}{6}) \end{bmatrix} = \frac{1}{2} \begin{bmatrix} \sqrt{3} & -1 \\ 1 & \sqrt{3} \end{bmatrix}$$

$$\mathbf{A}_4 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \quad \det(\mathbf{A}_4) = 2 \cdot 0$$


$$\mathbf{A}_5 = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix} \quad \det(\mathbf{A}_5) = 1.5 \cdot 0.5$$



$$\lambda_1 = 2.0$$

$$\lambda_2 = 0.5$$



$$\det(\mathbf{A}) = 1.0$$



$$\lambda_1 = 1.0$$

$$\lambda_2 = 1.0$$



$$\det(\mathbf{A}) = 1.0$$



$$\lambda_1 = (0.87-0.5j)$$

$$\lambda_2 = (0.87+0.5j)$$



$$\det(\mathbf{A}) = 1.0$$



$$\lambda_1 = 0.0$$

$$\lambda_2 = 2.0$$


$$\det(\mathbf{A}) = 0.0$$



$$\lambda_1 = 0.5$$

$$\lambda_2 = 1.5$$

$$\det(\mathbf{A}) = 0.75$$



Autoespectro de uma Rede Neural Biológica

- Análise e aprendizado através de dados em rede
- Conectividade entre nós de rede
- Se está conectado ou não
- Aplicações em Ciência de Dados



Os autovetores $\mathbf{x}_1, \dots, \mathbf{x}_n$ de uma matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ com n autovalores distintos $\lambda_1, \dots, \lambda_n$ são linearmente independentes.

Um matriz $\mathbf{A} \in \mathbb{R}^{n \times n}$ é defeituosa se ela possui menos de n autovetores linearmente independentes, não necessariamente com autovalores distintos, mas que ainda assim formam bases de \mathbb{R}^n .

Dada uma matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$, sempre podemos obter uma matriz simétrica, semidefinida positiva $\mathbf{S} \in \mathbb{R}^{n \times n}$ definindo $\mathbf{S} := \mathbf{A}^T \mathbf{A}$

Se $rk(\mathbf{A}) = n$, então $\mathbf{S} := \mathbf{A}^T \mathbf{A}$ é simétrica, definida positiva.

$$\begin{bmatrix} 10 & 2 & 1 \\ 2 & 1 & -2 \\ 1 & -2 & 10 \end{bmatrix}$$



Teorema Espectral

Se $A \in \mathbb{R}^{n \times n}$ for simétrica, existe uma base ortonormal do espaço vetorial correspondente V que consiste de autovetores de A , e cada autovalor é real.

Uma implicação direta do teorema espectral é que a decomposição de autovalores de uma matriz simétrica A existe (com autovalores reais) e que podemos encontrar uma base ortogonal de autovetores de modo que $A = PDP^T$.

- P é a matriz cujas colunas são os autovetores de A .
- D é a matriz diagonal formada pelos autovalores de A .



Considere a matriz:

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}$$

O polinômio característico de A é $p_A(\lambda) = -(\lambda - 1)^2(\lambda - 7)$, então os autovalores são $\lambda_1 = 1$ e $\lambda_2 = 7$.

Seguindo o procedimento padrão para cálculo de autovetores, obtemos:

$$E_1 = \text{span}\left[\underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}}_{=:x_1}, \underbrace{\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}}_{=:x_2}\right], \quad E_7 = \text{span}\left[\underbrace{\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}}_{=:x_3}\right].$$



O teorema espectral afirma que existe uma base ortogonal na decomposição de uma matriz simétrica, mas a base que temos não é ortogonal.

- \mathbf{x}_3 é ortogonal tanto a \mathbf{x}_1 quanto a \mathbf{x}_2 .
- \mathbf{x}_1 e \mathbf{x}_2 não são ortogonais entre si uma vez que: $\mathbf{x}_1^T \mathbf{x}_2 = 1 \neq 0$.

Aproveitamos o fato de que $\mathbf{x}_1, \mathbf{x}_2$ são autovetores associados ao mesmo autovalor λ para construir uma base ortogonal. Considerando que qualquer $\alpha, \beta \in \mathbb{R}$ temos que:

$$A(\alpha \mathbf{x}_1 + \beta \mathbf{x}_2) = A\mathbf{x}_1\alpha + A\mathbf{x}_2\beta = \lambda(\alpha \mathbf{x}_1 + \beta \mathbf{x}_2)$$

Utilizando o algoritmo de Gram-Schmidt conseguimos obter novos autovetores associados


$$\mathbf{x}'_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}'_2 = \frac{1}{2} \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}$$



Utilizando o algoritmo de Gram-Schmidt conseguimos obter novos autovetores associados a λ_1 :

$$\mathbf{x}'_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}'_2 = \frac{1}{2} \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix},$$

que são ortogonais entre si, ortogonais a \mathbf{x}_3 e autovetores de \mathbf{A} associados a $\lambda_1 = 1$.



PageRank - Ranqueamento de Páginas do Google

O PageRank foi desenvolvido na Universidade de Stanford por Larry Page e Sergey Brin em 1996.

O PageRank utiliza o autovetor correspondente ao autovalor máximo de uma matriz A para determinar a classificação de uma página nos resultados de pesquisa.

O algoritmo calcula o peso (importância) $x_i \geq 0$ de um site da web a_i contando o número de páginas que fazem *link* para a_i considerando no calculo desse peso também o peso das páginas quem fazem *link*.



O que aprendemos?

Determinante: é uma medida da "escala" de uma transformação linear representada pela matriz.

Traço: é a soma dos elementos da diagonal principal. Ele fornece informações sobre a soma dos autovalores da matriz.

Autovalores e Autovetores: são as características especiais que utilizamos para entender como uma matriz age sobre o espaço vetorial, identificando as direções principais ao longo das quais ocorrem as transformações e os fatores pelos quais essas transformações ocorrem.

Essas características são fundamentais na teoria das matrizes e têm aplicações em uma variedade de áreas, incluindo física, engenharia, ciência da computação, estatística e muito mais.



CCO0446 - TÓPICOS ESPECIAIS EM FUNDAMENTOS DE COMPUTAÇÃO 1

4.3 - Decomposição de Cholesky

4.4 - Decomposição em autovalores e autovetores e diagonalização

Alunos:

André Morais Riccioppo

Fábio Alves Martins Pereira

Gabriel Matheus Faria de Almeida

Hudson de Paula Romualdo



4.3 - Decomposição de Cholesky



4.3 - Decomposição de Cholesky

- Existem muitas maneiras de fatorar tipos especiais de matrizes que encontramos frequentemente no aprendizado de máquina.
- Nos números reais positivos, temos a operação de raiz quadrada que nos dá uma decomposição do número em componentes idênticos, por exemplo, $9 = 3 \cdot 3$.
- Para matrizes, precisamos ter cuidado para calcular uma operação semelhante a raiz quadrada.
- Para matrizes definidas positivas e simétricas (ver Seção 3.2.3), podemos escolher entre uma série de operações equivalentes de raiz quadrada.
- A decomposição de Cholesky, ou fatoração de Cholesky é uma delas e ela nos fornece uma equivalente à raiz quadrada quando temos matrizes definidas positivas e simétricas



4.3 - Decomposição de Cholesky

Theorem 4.18 (Cholesky Decomposition). *A symmetric, positive definite matrix A can be factorized into a product $A = LL^T$, where L is a lower-triangular matrix with positive diagonal elements:*

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{n1} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}. \quad (4.44)$$

L is called the Cholesky factor of A , and L is unique.



4.3 - Decomposição de Cholesky

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \mathbf{L}\mathbf{L}^T = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix}$$

$$\mathbf{A} = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}.$$



4.3 - Decomposição de Cholesky

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

$$\mathbf{A} = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}.$$

Se compararmos o lado esquerdo de e o lado direito, podemos ver que existe um padrão para os elementos da diagonal

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}$$



4.3 - Decomposição de Cholesky

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

$$\mathbf{A} = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix}.$$

E a mesma coisa vale para os elementos abaixo da diagonal, que também seguem um padrão

$$l_{21} = \frac{1}{l_{11}}a_{21}, \quad l_{31} = \frac{1}{l_{11}}a_{31}, \quad l_{32} = \frac{1}{l_{22}}(a_{32} - l_{31}l_{21}).$$



4.3 - Decomposição de Cholesky

Calculamos apeans os elementos da diagonal inferior, pois a matriz é simétrica

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}$$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \mathbf{L}\mathbf{L}^T = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix}$$



4.3 - Decomposição de Cholesky

A principal conclusão é que podemos tirar é que:

Podemos calcular retroativamente quais deveriam ser os componentes l_{ij} para L , se tivermos os valores a_{ij} para A , e os valores previamente calculados de l_{ij} .

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)}$$

$$l_{21} = \frac{1}{l_{11}}a_{21}, \quad l_{31} = \frac{1}{l_{11}}a_{31}, \quad l_{32} = \frac{1}{l_{22}}(a_{32} - l_{31}l_{21}).$$



4.3 - Decomposição de Cholesky

normal state circuit (Gómez-Rodríguez et al., 2014; Tang and Fleming, 2014). The Cholesky decomposition also allows us to compute determinants very efficiently. Given the Cholesky decomposition $\mathbf{A} = \mathbf{L}\mathbf{L}^\top$, we know that $\det(\mathbf{A}) = \det(\mathbf{L})\det(\mathbf{L}^\top) = \det(\mathbf{L})^2$. Since \mathbf{L} is a triangular matrix, the determinant is simply the product of its diagonal entries so that $\det(\mathbf{A}) = \prod_i l_{ii}^2$. Thus, many numerical software packages use the



4.4 - Decomposição em autovalores e autovetores e diagonalização



4.4 - Decomposição em autovalores e autovetores e diagonalização

Uma matriz diagonal é uma matriz que tem valor zero em todos os elementos fora da diagonal, ou seja, eles têm a forma

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}.$$



4.4 - Decomposição em autovalores e autovetores e diagonalização

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}.$$

As matrizes diagonais são importantes pois elas permitem o cálculo rápido de:

Determinantes

Potências

inversas.

O determinante é o produto dos elementos da diagonal

A potência D^k é dada por cada elemento diagonal elevado à potência k ,

O inverso D^{-1} é o inverso de seus elementos diagonais se todos eles forem diferentes de zero.



4.4 - Decomposição em autovalores e autovetores e diagonalização

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}.$$

Agora vamos ver como transformar matrizes em sua forma diagonal.

Essa transformação é uma aplicação importante da mudança de base e de autovalores, que foram discutidos nas seções anteriores.



4.4 - Decomposição em autovalores e autovetores e diagonalização

$$D = \begin{bmatrix} c_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & c_n \end{bmatrix}.$$

Lembremos que duas matrizes A , D são “semelhantes” (Definição 2.22) se existir uma matriz invertível P , tal que $D = P^{-1}AP$.

Mais especificamente, nós queremos examinar matrizes A que são semelhantes às matrizes diagonais D que contêm os autovalores de A na diagonal.



4.4 - Decomposição em autovalores e autovetores e diagonalização

Definition 4.19 (Diagonalizable). A matrix $A \in \mathbb{R}^{n \times n}$ is *diagonalizable* if it is similar to a diagonal matrix, i.e., if there exists an invertible matrix $P \in \mathbb{R}^{n \times n}$ such that $D = P^{-1}AP$.



4.4 - Decomposição em autovalores e autovetores e diagonalização

Let $A \in \mathbb{R}^{n \times n}$, let $\lambda_1, \dots, \lambda_n$ be a set of scalars, and let p_1, \dots, p_n be a set of vectors in \mathbb{R}^n . We define $P := [p_1, \dots, p_n]$ and let $D \in \mathbb{R}^{n \times n}$ be a diagonal matrix with diagonal entries $\lambda_1, \dots, \lambda_n$. Then we can show that

$$AP = PD \quad (4.50)$$

if and only if $\lambda_1, \dots, \lambda_n$ are the eigenvalues of A and p_1, \dots, p_n are corresponding eigenvectors of A .



4.4 - Decomposição em autovalores e autovetores e diagonalização

We can see that this statement holds because

$$AP = A[p_1, \dots, p_n] = [Ap_1, \dots, Ap_n], \quad (4.51)$$

$$PD = [p_1, \dots, p_n] \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix} = [\lambda_1 p_1, \dots, \lambda_n p_n]. \quad (4.52)$$

Thus, (4.50) implies that

$$Ap_1 = \lambda_1 p_1 \quad (4.53)$$

$$\vdots$$

$$Ap_n = \lambda_n p_n. \quad (4.54)$$

Therefore, the columns of P must be eigenvectors of A .



4.4 - Decomposição em autovalores e autovetores e diagonalização

Our definition of diagonalization requires that $\mathbf{P} \in \mathbb{R}^{n \times n}$ is invertible, i.e., \mathbf{P} has full rank (Theorem 4.3). This requires us to have n linearly independent eigenvectors $\mathbf{p}_1, \dots, \mathbf{p}_n$, i.e., the \mathbf{p}_i form a basis of \mathbb{R}^n .



4.4 - Decomposição em autovalores e autovetores e diagonalização

Theorem 4.20 (Eigendecomposition). *A square matrix $A \in \mathbb{R}^{n \times n}$ can be factored into*

$$A = PDP^{-1}, \quad (4.55)$$

where $P \in \mathbb{R}^{n \times n}$ and D is a diagonal matrix whose diagonal entries are the eigenvalues of A , if and only if the eigenvectors of A form a basis of \mathbb{R}^n .



4.4 - Decomposição em autovalores e autovetores e diagonalização

O Teorema 4.20 implica que apenas matrizes não defeituosas podem ser diagonalizadas e que as colunas de P são os n autovetores de A .

Uma matriz é dita "não defeituosa" se ela possui um conjunto completo de autovalores e autovetores linearmente independentes.

Em outras palavras, uma matriz não defeituosa é diagonalizável e pode ser decomposta em uma forma diagonal.

Para matrizes simétricas podemos obter resultados ainda mais fortes para a decomposição de autovalores.



4.4 - Decomposição em autovalores e autovetores e diagonalização

Theorem 4.21. *A symmetric matrix $S \in \mathbb{R}^{n \times n}$ can always be diagonalized.*




4.4 - Decomposição em autovalores e autovetores e diagonalização


Theorem 4.21. *A symmetric matrix $S \in \mathbb{R}^{n \times n}$ can always be diagonalized.*



4.4 - Decomposição em autovalores e autovetores e diagonalização



4.4 - Decomposição em autovalores e autovetores e diagonalização




Intuição por trás da decomposição em autovalores e autovetores como uma sequência de transformações.

Do canto superior esquerdo para o canto inferior esquerdo: P^{-1} executa uma mudança de base (aqui desenhada em \mathbb{R}^2 e representada como uma operação de rotação) da base padrão para a base de autovetores.




4.4 - Decomposição em autovalores e autovetores e diagonalização

Da parte inferior esquerda para a parte inferior direita: D realiza uma operação de escala ao longo dos autovetores ortogonais, representados aqui por um círculo sendo esticado em uma elipse.



4.4 - Decomposição em autovalores e autovetores e diagonalização



Da parte inferior direita para a parte superior direita: P desfaz a mudança de base (representada como uma rotação reversa) voltando ao sistema de coordenadas originais.



Decomposição em Valores Singulares

André M. Riccioppo



Decomposição em Valores Singulares

- SVD (Singular Value Decomposition)
- Permite uma análise de uma matriz usando partes mais simples e significativas.
- Como pode ser aplicada a todos tipos de matrizes, não só às matrizes quadradas, já foi chamada de teorema fundamental da álgebra linear.



Teorema

Dada uma matriz retangular $A \in \mathbb{R}^{m \times n}$ de posto $r \in [0, \min(m, n)]$, a SVD de A é uma decomposição na forma

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ n \end{array}$$



Matriz U

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ n \end{array}$$

- $U \in \mathbb{R}^{m \times m}$ é uma matriz ortogonal com colunas $u_i, i = 1, \dots, m$
- As colunas u_i são chamadas vetores singulares à esquerda
- São os autovetores da matriz AA^T
- Esses autovetores formam uma base ortogonal para o espaço das linhas de A



Matriz V

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ u \end{array}$$

- $V \in \mathbb{R}^{n \times n}$ é uma matriz ortogonal com colunas $v_j, j = 1, \dots, n$
- As colunas v_i são chamadas vetores singulares à direita
- São os autovetores da matriz $A^T A$
- Esses autovetores formam uma base ortogonal para o espaço das colunas de A



Matriz Σ

$$\begin{matrix} & n \\ m & \boxed{A} \end{matrix} = \begin{matrix} & m \\ m & \boxed{U} \end{matrix} \begin{matrix} & n \\ m & \boxed{\Sigma} \end{matrix} \begin{matrix} & n \\ \boxed{V^T} & n \end{matrix}$$

- Σ é uma matriz diagonal $m \times n$ com $\Sigma_{ii} = \sigma_i \geq 0$ e $\Sigma_{ij} = 0, i \neq j$.
- As entradas diagonais $\sigma_i, i = 1, \dots, r$ de Σ são chamadas de valores singulares
- Por convenção, os valores singulares são ordenados: $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$.



Matriz Σ

$$\begin{array}{c} n \\ \boxed{A} \\ m \end{array} = \begin{array}{c} m \\ \boxed{U} \\ m \end{array} \begin{array}{c} n \\ \boxed{\Sigma} \\ m \end{array} \begin{array}{c} n \\ \boxed{V^T} \\ n \end{array}$$

- $\Sigma \in \mathbb{R}^{m \times n}$ é retangular e do mesmo tamanho que A .
- Isso significa que Σ possui uma submatriz diagonal que contém os valores singulares e precisa ser preenchida com 0 se $m \neq n$.

se $m > n$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & \dots & 0 \\ \vdots & & \vdots \\ 0 & \dots & 0 \end{bmatrix}$$

se $m < n$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 & \dots & 0 \\ 0 & \ddots & 0 & \vdots & & \vdots \\ 0 & 0 & \sigma_m & 0 & \dots & 0 \end{bmatrix}$$




Interpretação geométrica da SVD

- A SVD de uma matriz pode ser interpretada como a decomposição de uma transformação linear $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$ em três operações:
 - Uma mudança de base via V^T (rotação)
 - Uma escala e dilatação (ou contração) de sua dimensionalidade através da matriz de valor singular Σ
 - Ao final, realiza uma segunda mudança de base via U (nova rotação).



Interpretação geométrica da SVD



Exemplo


Considere um mapeamento de um grid quadrado de vetores $X \in \mathbb{R}^2$ que se encaixa em um quadrado tamanho 2×2 centralizado na origem. Usando a base padrão, os vetores são mapeados usando:

$$A = \begin{bmatrix} 1 & -0,8 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = U\Sigma V^T = \begin{bmatrix} -0,79 & 0 & -0,62 \\ 0,38 & -0,78 & -0,49 \\ -0,48 & -0,62 & 0,62 \end{bmatrix} \begin{bmatrix} 1,62 & 0 \\ 0 & 1,0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -0,78 & 0,62 \\ -0,62 & -0,78 \end{bmatrix}$$




Exemplo

Início: conjunto de vetores X




Exemplo

Então aplica $V^T \in \mathbb{R}^{2 \times 2}$, que rotaciona X




Exemplo

Então esses vetores são mapeados usando a matriz de valor singular Σ para o codomínio \mathbb{R}^3 . Observe que todos vetores continuam no plano $x_1 - x_2$ e a terceira coordenada sempre é 0. Os vetores no plano $x_1 - x_2$ foram esticados pelos valores singulares.



Exemplo

U faz a rotação no codomínio \mathbb{R}^3 , de forma que os vetores mapeados não fiquem mais restritos ao plano $x_1 - x_2$, mas se mantêm em um plano.



Cálculo da SVD

- O cálculo da SVD de $A \in \mathbb{R}^{m \times n}$ é equivalente a encontrar
 - o conjunto ortonormal de vetores singulares à direita $v_1, \dots, v_n \in \mathbb{R}^n$, que vão gerar a matriz V
 - Depois, constrói-se o conjunto ortonormal de vetores singulares à esquerda $u_1, \dots, u_m \in \mathbb{R}^m$, que vão gerar a matriz U
 - Então, liga-se os dois e exige-se que a ortogonalidade de v_i seja preservada sob a transformação A . Isso é importante pois se sabe que as imagens Av_i formam um conjunto de vetores ortogonais. Essas imagens são normalizadas por fatores escalares, que correspondem aos valores singulares.



Cálculo da SVD

1 – Construção dos vetores singulares à direita (V)

- O teorema espectral indica que os autovetores de uma matriz simétrica formam uma base ortonormal, o que significa que podem ser diagonalizados.
- a partir de qualquer matriz retangular $A \in \mathbb{R}^{m \times n}$ podemos diagonalizar $A^T A$ e obter:

$$A^T A = P D P^T = P \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{bmatrix} P^T$$

onde P é uma matriz ortogonal, composta por uma autobase ortonormal. $\lambda_i \geq 0$ são os autovalores de $A^T A$.



Cálculo da SVD

1 – Construção dos vetores singulares à direita (V)

Assumindo-se que a SVD de $A = U\Sigma V^T$ existe:

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T$$

onde U , V são matrizes ortogonais.



Cálculo da SVD

1 – Construção dos vetores singulares à direita (V)

Assumindo-se que a SVD de $A = U\Sigma V^T$ existe:

$$A^T A = (U\Sigma V^T)^T (U\Sigma V^T) = V\Sigma^T U^T U\Sigma V^T$$

onde U, V são matrizes ortogonais. Então sendo $U^T U = I$, obtém-se:

$$A^T A = V\Sigma^T \Sigma V^T = V \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n^2 \end{bmatrix} V^T$$

- Comparando, podemos identificar:

$$V^T = P^T$$

$$\sigma_i^2 = \lambda_i$$

- Então, os autovetores de $A^T A$ que compõe P são os vetores singulares à direita de A (V). Os autovalores de $A^T A$ são os valores singulares de Σ .



Cálculo da SVD

2 – Construção dos vetores singulares à esquerda (U)

- Para obter os vetores singulares à esquerda usa-se um procedimento similar. Começa-se calculando a SVD da matriz simétrica $AA^T \in \mathbb{R}^{m \times m}$

$$AA^T = (U\Sigma V^T)(U\Sigma V^T)^T = U\Sigma \mathbf{V}^T \mathbf{V} \Sigma^T U^T = U \mathbf{\Sigma} \mathbf{\Sigma}^T U^T = U \begin{bmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_m^2 \end{bmatrix} U^T$$

- O teorema espectral diz que $AA^T = SDS^T$ pode ser diagonalizado e podemos encontrar uma base ortonormal de autovetores de AA^T , que são coletados em S . Os autovetores ortonormais de AA^T são os vetores singulares à esquerda (U) e formam uma base ortonormal no codomínio da SVD.
- Então, como AA^T e $A^T A$ possuem os mesmos autovalores diferentes de zero, as entradas não zero das matrizes Σ na SVD devem ser iguais para ambos os casos.



Cálculo da SVD

2 – Construção dos vetores singulares à esquerda (U)

- Para completar a construção da SVD, são necessários vetores singulares à esquerda que sejam ortonormais. Normaliza-se as imagens dos vetores singulares à direita Av_i , obtendo

$$u_i := \frac{Av_i}{\|Av_i\|} = \frac{1}{\sqrt{\lambda_i}} Av_i = \frac{1}{\sigma_i} Av_i$$

- Onde a última parte é obtida da equação que demonstra que os autovalores de AA^T são tais que $\sigma_i^2 = \lambda_i$.



Cálculo da SVD

3 – Obtenção dos valores singulares

- Então, os autovetores de $A^T A$, que sabemos ser os vetores singulares à direita v_i , e suas imagens normalizadas sob A, os vetores singulares à esquerda u_i formam duas bases ortonormais auto consistentes que são conectados através da matriz de valor singular Σ .
- Concatenando v_i como as colunas de V e u_i como as colunas de U, temos
$$AV = U \Sigma$$
- onde Σ tem as mesmas dimensões que A e uma estrutura diagonal de linhas 1, ..., r. Desta forma, temos que $A = U \Sigma V^T$, que é a SVD de A.



Exemplo

Cálculo da SVD de uma matriz

$$A = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix}$$

Passo 1 – calcular os vetores singulares à direita à partir da base de autovetores de $A^T A$.

- Primeiro serão calculados os vetores singulares à direita de $A^T A$. Inicia-se com o cálculo de $A^T A$.

$$A^T A = \begin{bmatrix} 1 & -2 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$



Exemplo

- Através da decomposição em autovalores de $A^T A$, obtemos a matriz P formada pelos autovetores de A e matriz diagonal D com os autovalores de A

$$A^T A = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{-1}{\sqrt{6}} \\ \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} 6 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} & \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{30}} \\ 0 & \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{-1}{\sqrt{6}} & \frac{-2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix} = P D P^T$$



Exemplo

Os vetores singulares à direita são obtidos pelas colunas de P, portanto

$$V = \begin{bmatrix} \frac{5}{\sqrt{30}} & 0 & \frac{-1}{\sqrt{6}} \\ \frac{-2}{\sqrt{30}} & \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{6}} \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$



Exemplo

Passo 2 – calcular a matriz de valores singulares

- Os valores singulares σ_i são as raízes quadradas dos autovalores de $A^T A$, obtidos da matriz D calculada no passo anterior.
- Como $\text{rk}(A) = 2$, existem apenas dois valores singulares diferentes de zero: $\sigma_1 = \sqrt{6}$ e $\sigma_2 = 1$. A matriz de valor singular deve ser do mesmo tamanho que A, então obtemos

$$\Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$



Exemplo

Passo 3 – calcular a os vetores singulares à esquerda como imagem normalizada dos vetores singulares à direita.

- Os vetores singulares à esquerda são obtidos pelo cálculo da imagem dos vetores singulares à direita em A, que são normalizados pela divisão por seu valor singular correspondente.

$$u_1 = \frac{1}{\sigma_1} A v_1 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{5}{\sqrt{30}} \\ -2 \\ \frac{1}{\sqrt{30}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ 2 \\ -\frac{1}{\sqrt{5}} \end{bmatrix}$$

$$u_2 = \frac{1}{\sigma_2} A v_2 = \frac{1}{1} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{0}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{5}} \\ 1 \\ \frac{1}{\sqrt{5}} \end{bmatrix}$$

$$U = [u_1, u_2] = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ -2 & 1 \end{bmatrix}$$



Conclusões

- A SVD é comparável à autodecomposição
 - Autodecomposição: só matrizes quadradas com base de autovetores
 - SVD: qualquer matriz retangular
- Ambas são composições de três transformações lineares:
 - uma mudança de base,
 - uma escala e transformação de domínio e
 - uma nova mudança de base.
- A SVD é usada em vários tipos de aplicações:
 - problemas de mínimos quadrados em ajuste de curvas,
 - resolução de sistemas de equações lineares,
 - redução de dimensionalidade,
 - modelagem de tópicos e
 - compressão e clusterização de dados.



Matrizes de aproximação

Gabriel M. Almeida



Decomposição de Valores Singulares (SVD)

- Decomposição espectral ($Ax = \lambda x$)
 - Aplica-se apenas a matrizes quadradas
- Na prática matrizes quadradas não são comuns
 - Matrizes esparsas
 - Estrutura em “blocos”

	Matrix	Alien	Serenity	Casablanca	Amelie	
↑	1	1	1	0	0	Ana
SciFi	3	3	3	0	0	Bruno
↓	4	4	4	0	0	...
	5	5	5	0	0	
↑	0	0	0	4	4	
Romance	0	0	0	5	5	
↓	0	0	0	2	2	



Decomposição de Valores Singulares (SVD)

- SVD completo

- $AV = U\Sigma \Leftrightarrow AVV^{-1} = U\Sigma V^{-1} \Leftrightarrow A = U\Sigma V^T$

$$A \underbrace{\begin{bmatrix} | & \dots & | & | & \dots & | \\ v_1 & \dots & v_r & v_{r+1} & \dots & v_n \\ | & \dots & | & | & \dots & | \end{bmatrix}}_{n \times n} = \underbrace{\begin{bmatrix} | & \dots & | & | & \dots & | \\ u_1 & \dots & u_r & u_{r+1} & \dots & u_m \\ | & \dots & | & | & \dots & | \end{bmatrix}}_{m \times m} \underbrace{\begin{bmatrix} \sigma_1 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & \sigma_r & 0 & \dots & 0 \\ 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix}}_{m \times n}$$



Decomposição de Valores Singulares (SVD)

- O SVD de A ($m \times n$) e posto r origina r valores singulares (σ)
 - As matrizes V , U e Σ , não são matrizes quadradas
 - SVD reduzido

$$A \begin{bmatrix} v_1 & v_2 & \dots & v_r \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \dots & u_r \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \end{bmatrix}$$



Decomposição de Valores Singulares (SVD)

- Exemplo de aplicação de SVD
 - Matriz A tem posto dois, resultando em 2 valores singulares e matrizes U e V com 2 vetores colunas
- Número de conceitos é relacionado ao posto da matriz

$$\begin{array}{c}
 \begin{array}{c} \uparrow \\ \text{SciFi} \\ \downarrow \end{array} \\
 \begin{array}{c} \uparrow \\ \text{Romance} \\ \downarrow \end{array}
 \end{array}
 \begin{array}{c}
 \text{Matrix} \\
 \text{Alien} \\
 \text{Serenity} \\
 \text{Casablanca} \\
 \text{Amelie}
 \end{array}
 \begin{bmatrix}
 1 & 1 & 1 & 0 & 0 \\
 3 & 3 & 3 & 0 & 0 \\
 4 & 4 & 4 & 0 & 0 \\
 5 & 5 & 5 & 0 & 0 \\
 0 & 0 & 0 & 4 & 4 \\
 0 & 0 & 0 & 5 & 5 \\
 0 & 0 & 0 & 2 & 2
 \end{bmatrix}
 =
 \begin{bmatrix}
 0.14 & 0.00 \\
 0.42 & 0.00 \\
 0.56 & 0.00 \\
 0.70 & 0.00 \\
 0.00 & 0.60 \\
 0.00 & 0.75 \\
 0.00 & 0.30
 \end{bmatrix}
 \times
 \begin{bmatrix}
 12.4 & 0 \\
 0 & 9.5
 \end{bmatrix}
 \times
 \begin{bmatrix}
 0.58 & 0.58 & 0.58 & 0.00 & 0.00 \\
 0.00 & 0.00 & 0.00 & 0.71 & 0.71
 \end{bmatrix}$$



Decomposição de Valores Singulares (SVD)

- Exemplo de aplicação de SVD
 - Matriz A de posto 3 e valor singular σ_1 , σ_2 e σ_3

Matrix A (6x5) is decomposed into U (6x3), Σ (3x3), and V^T (3x5).

Matrix A (Ratings):

	Matrix	Alien	Serenity	Casablanca	Amelie
SciFi	1	1	1	0	0
	3	3	3	0	0
	4	4	4	0	0
	5	5	5	0	0
Romance	0	2	0	4	4
	0	0	0	5	5
	0	1	0	2	2

Matrix U (6x3):

0.13	-0.02	-0.01
0.41	-0.07	-0.03
0.55	-0.09	-0.04
0.68	-0.11	-0.05
0.15	0.59	0.65
0.07	0.73	-0.67
0.07	0.29	0.32

Matrix Σ (3x3):

12.4	0	0
0	9.5	0
0	0	1.3

Matrix V^T (3x5):

0.56	0.59	0.56	0.09	0.09
-0.12	0.02	-0.12	0.69	0.69
0.40	-0.80	0.40	0.09	0.09



Matriz de aproximação

- Removendo um valor singular (σ_3)
 - Matriz de aproximação calculada com σ_1 e σ_2

The diagram illustrates the process of removing a singular value (σ_3) from a matrix approximation. It shows the following components:

- Genre Matrix (Left):** A 6x5 matrix with rows for SciFi and Romance, and columns for Matrix, Alien, Serenity, Casablanca, and Amelie. The values are:

	Matrix	Alien	Serenity	Casablanca	Amelie
SciFi	1	1	1	0	0
	3	3	3	0	0
	4	4	4	0	0
	5	5	5	0	0
Romance	0	2	0	4	4
	0	0	0	5	5
	0	1	0	2	2
- Singular Value Matrix (Middle):** A 6x3 matrix of singular values, with the third column crossed out:

0.13	-0.02	-0.01
0.41	-0.07	-0.03
0.55	-0.09	-0.04
0.68	-0.11	-0.05
0.15	0.59	0.55
0.07	0.73	-0.67
0.07	0.29	0.32
- Reconstructed Matrix (Right):** A 6x5 matrix calculated using the first two singular values, with the third column crossed out:

12.4	0	0		
0	9.5	0		
0	0	1.5		
0.56	0.59	0.56	0.09	0.09
-0.12	0.02	-0.12	0.69	0.69
0.40	-0.80	0.40	0.69	0.09

Green 'X' marks indicate the multiplication of the genre matrix by the singular value matrix to produce the reconstructed matrix.



Matriz de aproximação

- Aproximação de matrizes - **Exemplo de aplicação**
 - Algoritmos de recomendação
 - Lojas virtuais, streaming, propagandas
- Considerando k usuários
 - Cada usuário é o resultado da combinação linear dos conceitos e a matriz original A terá posto k
 - Quais filmes recomendar para um usuário baseado em seu perfil?



Matriz de aproximação

- Exemplo de recomendação
 - Excluindo linhas e colunas de U , V e Σ obtemos uma recomendação dos filmes para os usuários destacados

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 0 & 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.14 & -0.06 & -0.04 \\ 0.30 & -0.11 & -0.61 \\ 0.43 & -0.16 & 0.76 \\ 0.74 & -0.31 & -0.18 \\ 0.15 & 0.53 & 0.02 \\ 0.07 & 0.70 & -0.03 \\ 0.07 & 0.27 & 0.01 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.51 & 0.66 & 0.44 & 0.23 & 0.23 \\ -0.24 & -0.13 & -0.21 & 0.66 & 0.66 \\ 0.59 & 0.08 & -0.80 & 0.01 & 0.01 \end{bmatrix}$$



Matriz de aproximação

- Exemplo de recomendação
 - Excluindo linhas e colunas de U , V e Σ obtemos uma recomendação dos filmes para os usuários destacados

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 0 & 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix} = \begin{bmatrix} 0.14 & -0.06 & -0.04 \\ 0.30 & -0.11 & -0.61 \\ 0.43 & -0.16 & 0.76 \\ 0.74 & -0.31 & -0.18 \\ 0.15 & 0.53 & 0.02 \\ 0.07 & 0.70 & -0.03 \\ 0.07 & 0.27 & 0.01 \end{bmatrix} \times \begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix} \times \begin{bmatrix} 0.51 & 0.66 & 0.44 & 0.23 & 0.23 \\ -0.24 & -0.13 & -0.21 & 0.66 & 0.66 \\ 0.59 & 0.08 & -0.80 & 0.01 & 0.01 \end{bmatrix}$$

(Note: In the original image, the first matrix has red highlights on the first row and the third column. The second matrix has red lines crossing out the first column and the third row. The third matrix has a red 'X' over the third element in the second row. The fourth matrix has red lines crossing out the third row.)



Matriz de aproximação

- Exemplo de recomendação
 - Excluindo linhas e colunas de U , V e Σ obtemos uma recomendação dos filmes para os usuários destacados

Valores originais

1	1	1	0	0
0	3	3	0	0
4	4	0	0	0
5	5	5	0	0
0	2	0	4	4
0	0	0	5	5
0	1	0	2	2

Valores recomendação

0.96	1.14	0.82	-0.01	-0.01
1.94	2.32	1.66	0.07	0.07
2.77	3.32	2.37	0.08	0.08
4.84	5.74	4.14	-0.08	0.08
0.40	1.42	0.33	4.06	4.06
-0.42	0.63	-0.38	4.92	4.92
0.20	0.71	0.16	2.03	2.03



Matriz de aproximação

- Aproximação de matrizes - **Exemplo de aplicação**
 - Algoritmos de compressão de imagens
 - Reduzir custo de transmissão de imagens em redes
 - Reduzir tempo de transmissão de imagens
 - Reduzir custo de processamento de imagens por modelos de segmentação
 - Transmissão 4K (30 FPS) sem compressão demandaria uma transmissão de ~ 7 Gbps



Matriz de aproximação

- Seja a imagem representada por uma matriz A e a matriz de aproximação A_k (de posto k)
 - Podemos usar os k maiores valores singulares

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T$$




Matriz de aproximação


- Compressão de imagens
 - Imagem resultante para cada valor singular calculado




(a) Original image A .




(b) A_1 , $\sigma_1 \approx 228,052$.




(c) A_2 , $\sigma_2 \approx 40,647$.



(d) A_3 , $\sigma_3 \approx 26,125$.



(e) A_4 , $\sigma_4 \approx 20,232$.



(f) A_5 , $\sigma_5 \approx 15,436$.




Matriz de aproximação


- Compressão de imagens
 - Imagem resultante para cada valor singular calculado




(a) Original image A .




(b) Rank-1 approximation $\hat{A}(1)$.



(c) Rank-2 approximation $\hat{A}(2)$.



(d) Rank-3 approximation $\hat{A}(3)$.



(e) Rank-4 approximation $\hat{A}(4)$.




(f) Rank-5 approximation $\hat{A}(5)$.



Matriz de aproximação

- Compressão de imagens - exemplo cachorro (posto 3024)
 - Imagem resultante para cada valor singular calculado

Posto 1



Posto 10



Posto 100



Matriz de aproximação

- Compressão de imagens
 - Como verificar se a compressão é suficiente?
- Root Mean Square Error (RMSE)
 - Diferença média entre o pixel da matriz original e o pixel da matriz aproximada


$$RMSE = \sqrt{\frac{1}{MN} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} (I1(m,n) - I2(m,n))^2}$$



Matriz de aproximação

- Compressão de imagens
 - Quando parar de incluir valores singulares na compressão?
 - Regra do polegar: cortar de maneira a manter entre 80-90% da energia total

$$t = \frac{\sum_{i=1}^k \sigma^2}{\sum_{i=1}^n \sigma^2}$$



Matriz de aproximação

- Compressão de imagens
 - É possível encontrar uma matriz B de posto k que seja mais próxima de A e que não seja A_k ?
 - **Teorema de Eckart-Young:** Suponha uma matriz B de posto k. Então B será uma aproximação no máximo tão boa quanto A_k .

$$A_k = \sigma_1 u_1 v_1^T + \cdots + \sigma_k u_k v_k^T$$



Conclusão

- Parte 1 - Hudson Romualdo (hudson_romualdo@discente.ufg.br)
 - Determinante e Traço de matrizes
 - Autovalores e autovetores
- Parte 2 - Fábio Pereira (fabio.pereira@discente.ufg.br)
 - Decomposição de Cholesky
 - Decomposição de autovalores, autovetores e diagonalização
- Parte 3 - André Riccioppo (andre.riccioppo@discente.ufg.br)
 - Decomposição em valores singulares
- Parte 4 - Gabriel Almeida (gabrielmatheus05@discente.ufg.br)
 - Aproximação de matrizes

